

LLM 中文文本生成系统

用户操作手册

V1.0

编制日期：2026 年 9 月

文档说明

本手册面向教师、编辑、研究人员和系统维护人员，说明软件的安装、配置、内容生成、质量评估、批量处理、模型微调 and 结果查看方法。基础模式无需网络、显卡或外部模型即可完成全部 workflow 演示。

项目	说明
软件名称	LLM 中文文本生成系统
版本	V1.0
运行方式	命令行应用
基础环境	Python 3.10 及以上
默认模式	离线模板生成与规则质量评估
可选能力	本地 Transformers 模型生成与 LoRA 微调

目录

- 1 软件概述
- 2 安装与启动
- 3 快速演示
- 4 单篇内容生成
- 5 文本质量评估
- 6 批量任务处理
- 7 训练数据准备
- 8 LoRA 模型微调
- 9 配置说明
- 10 输出文件说明
- 11 常见问题与故障处理

- 12 数据安全与使用边界
- 13 软件卸载

1 软件概述

1.1 软件用途

系统围绕小学、初中和高中三个阅读等级，完成中文阅读材料生成、自动质量检查和批量报告导出。它解决原始研究脚本入口分散、路径依赖、环境配置不一致和结果难以汇总的问题，把模型生成、文本统计和分级评估组织为可重复执行的软件流程。

1.2 核心功能

- 按主题、学段、关键词和附加要求生成中文阅读材料。
- 使用离线模板后端完成安装验收，或接入用户拥有的本地语言模型。
- 计算汉字数、句数、段落数、平均句长、重复率、英文比例和难度匹配度。
- 按优秀、良好、合格、待改进给出综合结论，并列出警告和修改建议。
- 从 JSONL 读取批量任务，隔离单条异常并输出 HTML、CSV、JSON 和 JSONL 报告。
- 把带学段标签的文本转换为训练数据，并对兼容模型执行 LoRA 微调。

1.3 工作流程

用户先选择生成后端并给出主题。系统校验请求后生成正文，将正文交给评估器计算统计指标和综合分，再把文章、分数、提示与元数据写入结构化结果。批量模式会重复这一流程，并在结束后生成汇总报告。

2 安装与启动

2.1 环境要求

类别	最低要求	建议配置
操作系统	Windows 10、常见 Linux 或 macOS	64 位桌面或服务器系统

类别	最低要求	建议配置
Python	3.10	3.11 或 3.12
内存	4 GB	8 GB 以上
磁盘	基础软件 50 MB 内	按本地模型体积预留空间
显卡	基础模式不需要	模型模式按模型规模配置 CUDA 显卡

2.2 安装基础软件

在命令行进入软件根目录，即包含 `pyproject.toml` 的目录，执行以下命令。安装过程只安装本软件基础包，默认不下载大模型。

```
python -m pip install -e .
llmctg --version
```

看到 `llmctg 1.0.0` 表示入口安装成功。若不执行安装，也可以将 `src` 目录加入 `PYTHONPATH` 后使用 `python -m llmctg`。

2.3 安装模型扩展

只有需要加载本地 Hugging Face 模型或执行 LoRA 微调时才安装扩展依赖。模型权重不包含在本软件中，应由用户从合法来源准备。

```
python -m pip install -e ".[llm]"
```

3 快速演示

快速演示不调用外部模型，会分别生成小学、初中和高中示例，完成自动评分并输出报告。

```
llmctg demo --output output/demo
```

文件	用途
articles.jsonl	逐条保存文章、请求信息和完整评估结果
summary.json	保存数量、通过数、平均分和异常数

文件	用途
summary.csv	用于办公软件筛选和统计
report.html	用于浏览器阅读文章和质量提示

4 单篇内容生成

4.1 基本命令

```
llmctg generate --topic "海洋" --level junior --count 2 --seed 2026 --output
output/ocean.jsonl
```

参数	是否必填	说明
--topic	是	文章主题，不允许为空
--level	否	primary、junior、senior 或中文学段，默认 junior
--instruction	否	补充内容范围、体裁或表达要求
--keywords	否	用中文或英文逗号分隔
--count	否	一次生成 1 至 20 篇
--seed	否	固定随机种子以便复现
--backend	否	template 或 transformers
--output	否	JSONL 文件；省略时打印到终端

4.2 指定本地模型

```
llmctg generate --backend transformers --model-path D:/models/Qwen --device auto --topic "
城市生态" --level senior
```

系统会在首次生成时加载模型。**device** 为 **auto** 时优先使用可用 **CUDA**，否则使用 **CPU**。为降低供应链风险，软件不会执行模型目录中的远程自定义代码。

5 文本质量评估

5.1 评估直接输入文本

```
llmctg evaluate --text "春天来了。小草从泥土里探出头。" --level primary
```

5.2 评估文本文件

```
llmctg evaluate --input article.txt --level junior --output output/evaluation.json
```

5.3 理解评估结果

指标	含义
overall_score	结构、长度、等级匹配和流畅性的加权总分
predicted_level	根据句长和字词难度估算的阅读等级
repetition_rate	连续四字片段的重复程度
english_ratio	英文字符占全文字符的比例
uncommon_character_ratio	不在内置常用字集合中的汉字比例
warnings	触发阈值的质量问题
suggestions	针对问题生成的修改建议

自动评估是编辑辅助工具，不能判断所有事实是否真实，也不能代替教师、编辑或学科专家的最终审核。

6 批量任务处理

6.1 准备任务文件

任务文件采用 JSONL，即每一行是一个独立 JSON 对象。主题 `topic` 必填，其他字段可省略。

```
{"topic":"森林里的水循环","level":"primary","keywords":["树叶","雨水"]}
{"topic":"数据如何影响公共决策","level":"senior","instruction":"说明证据边界"}
```

6.2 执行任务

```
llmctg batch --input examples/tasks.jsonl --output output/batch
```

默认启用断点续作。系统为每条源任务计算稳定编号，已完成任务会跳过。若需要重新计算，可使用 `--no-resume` 并选择新的输出目录。单条任务失败后，原因写入 `errors.jsonl`，其余任务继续执行。

7 训练数据准备

原始文本每行由正文、制表符和等级标签构成。等级可使用 0、1、2 或小学、初中、高中。转换器会生成带 `instruction`、`input`、`output` 和 `level` 字段的 JSONL。

```
llmctg prepare-data --input train.txt --output data/train.jsonl
```

8 LoRA 模型微调

微调前应确认基础模型和训练语料的授权，准备足够磁盘与显存，并先使用少量样本验证流程。软件使用显式参数替代原始脚本中的个人绝对路径。

```
llmctg train --model-path D:/models/Qwen --dataset data/train.jsonl --output
models/reading-lora --epochs 3 --batch-size 1 --max-length 1024 --device auto
```

- 训练输出目录保存 LoRA 适配器和分词器配置。
- CUDA 环境启用半精度与梯度检查点；CPU 环境使用单精度。
- 若模型层名称与 `q_proj`、`k_proj`、`v_proj`、`o_proj` 不匹配，应由维护人员调整目标模块。
- 训练损失只反映拟合过程，不能代替独立测试集和人工内容评价。

9 配置说明

执行 `init-config` 可生成默认 JSON 配置。命令行中的后端、模型路径和设备会覆盖配置文件对应值。

```
llmctg init-config --output llmctg.json
llmctg --config llmctg.json generate --topic "气候"
```

配置项	默认值	说明
generation.backend	template	生成后端
generation.device	auto	推理设备
generation.temperature	0.9	采样随机性
generation.top_p	0.9	核采样阈值
generation.repetition_penalty	1.1	模型重复惩罚
evaluation.pass_score	60	质量通过分数
evaluation.repetition_warning	0.18	重复率警告阈值
log_level	INFO	日志级别

10 输出文件说明

JSON 和 JSONL 保存全部结构化信息，适合程序继续处理；CSV 以 UTF-8 BOM 编码，适合 Excel 等软件；HTML 报告完全本地化，可直接双击打开。生成时间采用带时区的 ISO 8601 格式。

11 常见问题与故障处理

现象	原因与处理方法
----	---------

现象	原因与处理方法
提示主题不能为空	检查 <code>--topic</code> 或批量任务 <code>topic</code> 字段，删除只有空格的值
提示不支持的阅读等级	使用 <code>primary</code> 、 <code>junior</code> 、 <code>senior</code> 、 <code>0</code> 、 <code>1</code> 、 <code>2</code> 或相应中文学段
提示缺少模型依赖	安装 <code>[llm]</code> 扩展，并确认当前命令使用同一 <code>Python</code> 环境
模型目录不存在	检查路径拼写与访问权限，不要填写网络模型名称代替本地目录
CUDA 显存不足	降低最大令牌数、使用更小模型或改用 <code>CPU</code>
批量任务部分失败	查看 <code>errors.jsonl</code> 的行号、异常类型和消息，修正后使用新目录重跑
中文在终端显示异常	将终端切换到 <code>UTF-8</code> ，文件本身仍按 <code>UTF-8</code> 保存
质量分低	查看 <code>warnings</code> 与 <code>suggestions</code> ，重点检查长度、长句、重复和等级匹配

12 数据安全与使用边界

- 默认后端完全离线，不向网络发送主题或文章。
- 本地模型后端只读取用户指定目录，但模型、语料和数据库授权由使用者负责确认。
- 请勿把含个人敏感信息、未授权作品或保密材料直接用于训练。
- 生成内容投入教学、出版或公开传播前，必须进行事实、版权、年龄适宜性和价值导向审核。
- 备份输出目录时应遵守所在单位的数据分类与保存制度。

13 软件卸载

使用 `pip` 安装时执行下列命令卸载程序。输出目录、模型和训练数据不会自动删除，应由用户确认后单独归档或清理。

```
python -m pip uninstall llmctg
```